Automatización del SAPI mediante Algoritmos de Aprendizaje Supervisado

Introducción

Los niños hospitalizados son susceptibles de presentar deterioro clínico durante su internación. Se ha descrito que presentan cambios fisiológicos y de conducta, horas antes de que esto suceda. La detección temprana del deterioro clínico de los pacientes hospitalizados posibilita una mejora en la calidad de atención médica. Esto permite la evaluación precoz del paciente crítico para determinar oportunamente su ingreso a una unidad de cuidados intensivos pediátricos o la realización de intervenciones mayores. Con este fin, se han diseñado diferentes escalas Pediatric Early Warning Score (PEWS) que permiten la evaluación rápida de los pacientes. Algunos ejemplos de PEWS empleados actualmente son: B-PEWS (Escala de Alerta Temprana Pediátrica de Brighton) que permite predecir el deterioro clínico basándose en tres aspectos: respiratorio, cardiovascular y conductual, la Escala de Anderson para distrés respiratorio y la triada del fallo respiratorio.

En España, el score SAPI (Sistemas de Alerta Precoz Infantil) es la herramienta más utilizada en la hospitalización pediátrica para identificar a los niños en riesgo de deterioro clínico grave. Estos sistemas funcionan mediante una puntuación numérica basada en parámetros fisiológicos y observaciones clínicas, lo que permite anticipar el deterioro y facilitar la atención temprana. Su diseño se basa en una escala numérica (0-9) que cuantifica el compromiso fisiológico mediante la evaluación de cuatro parámetros críticos: frecuencia cardíaca (FC), frecuencia respiratoria (FR), saturación de oxígeno (SpO_2) y la apariencia clínica, que engloba el estado general y el esfuerzo ventilatorio.

En la praxis clínica actual, la determinación del score SAPI se fundamenta en un procedimiento de cálculo manual ejecutado por el personal facultativo y de enfermería. Este enfoque metodológico conlleva limitaciones intrínsecas, destacando una significativa variabilidad inter-observador, particularmente crítica durante la evaluación subjetiva de parámetros fenotípicos como la apariencia o el estado de conciencia del paciente pediátrico. Asimismo, la elevada carga cognitiva inherente a entornos de alta presión asistencial incrementa la susceptibilidad al error humano y puede derivar en una latencia clínica no deseada, comprometiendo la agilidad necesaria en los procesos de triaje y estabilización.

El objetivo de este proyecto es implementar y validar un prototipo de sistema de ayuda a la decisión clínica que procese de forma automatizada las constantes vitales del paciente pediátrico y devuelva el valor del SAPI asociado. Se busca demostrar que la integración de algoritmos supervisados no solo aumenta la fiabilidad del diagnóstico de gravedad, sino que permite el diseño de interfaces de usuario orientadas a la monitorización continua, facilitando una medicina de precisión y una respuesta asistencial temprana.

Dada la marcada variabilidad fisiológica y la dependencia de los rangos de normalidad respecto a la madurez biológica, el presente sistema de ayuda a la decisión ha sido parametrizado

específicamente para la población lactante (rango de 0 a 11 meses). En consecuencia, el algoritmo procesa las constantes vitales mediante umbrales de puntuación ajustados a los estándares hemodinámicos y respiratorios de este grupo. No obstante, el modelo podría implementarse en otros estratos pediátricos mediante la actualización de las matrices de evaluación y los criterios de asignación de pesos en el score.

Métodos

Objetivos y proceso

La metodología de este trabajo se fundamenta en el desarrollo de un Sistema de Ayuda a la Decisión Clínica (SADC) para la automatización del score SAPI, un proceso que ha requerido una cuidadosa integración entre la ingeniería de datos y la realidad fisiológica pediátrica. En la fase inicial del proyecto, se planteó la necesidad de obtener un conjunto de datos robusto para el entrenamiento de los algoritmos. Ante la dificultad de acceder a bases de datos hospitalarias reales debido a las estrictas normativas de protección de datos de carácter personal y la sensibilidad de la información clínica en neonatología, se optó por la generación de un dataset sintético. Esta decisión permitió controlar con precisión las variables biológicas y asegurar una representación equitativa de los diferentes niveles de riesgo, algo fundamental para evitar sesgos en el aprendizaje automático. Se generó una muestra de 500 registros, tamaño suficiente para permitir una convergencia estadística adecuada en modelos supervisados sin incurrir en un sobreajuste excesivo.

El cálculo del score SAPI en este sistema se basa en una lógica de puntuación jerárquica que evalúa la frecuencia cardíaca, la frecuencia respiratoria, la saturación de oxígeno y la apariencia clínica. En un primer momento, la lógica seguida para la asignación de puntos SAPI fue la siguiente:

- FC: 0 ptos si es inferior a 140, 1 pto si es menor a 160, 2 ptos para el resto de los casos.
- FR: 0 ptos si es inferior a 40, 1 pto si es menor a 60, 2 ptos para el resto de los casos.
- SpO2: 0 ptos si es mayor o igual a 95, 1 si es mayor o igual a 90, 2 para el resto.
- Apariencia: número aleatorio entre 0 y 3, a los que se asignaban probabilidades de 0’4, 0’3, 0’2 y 0’1 respectivamente.

El primer algoritmo que se decidió implementar para entrenar el dataset fue el Árbol de Decisión con una profundidad max_depth = 3, ya que se trata de un algoritmo sencillo y con gran explicabilidad, lo cual resulta esencial en el ámbito médico. La precisión obtenida fue de un 68.00%, con un Support de 12 casos de la clase “Alto” frente a 59 de “Medio” y un Recall de “Alto” de 0’08. Esto evidenció que el modelo presentaba una baja precisión debido al bajo número de casos críticos en la muestra, un fenómeno común en medicina donde la mayoría de los pacientes no están en estado crítico, pero que, sin embargo, generaba un dataset desbalanceado. Para mejorar la precisión del modelo se optó por aumentar la profundidad del árbol a 5, logrando capturar un mayor número de combinaciones y obteniendo así un mayor número de casos críticos. Además, el factor “Apariencia” se generaba de forma completamente

aleatoria, lo cual dificultaba la tarea predictiva al modelo. Por ello, finalmente se ha definido como una variable que depende de la presión parcial de oxígeno. Si esta variable toma un valor inferior a 90, se asigna un número aleatorio entre 2 y 3 a la apariencia, en caso contrario, se le da un valor de 0 o 1. Con estas mejoras, la precisión del modelo subió a un 91.00%.

Sin embargo, en este dataset se habían establecido únicamente límites superiores para las constantes vitales, lo cual puede resultar en una simplificación clínicamente incompleta. A pesar de la alta precisión estadística obtenida con este modelo, se estaban obviando casos críticos no definidos en la lógica de cálculo del SAPI. En un lactante, el riesgo vital no solo se manifiesta mediante taquicardia o taquipnea, sino también a través de la bradicardia y la bradipnea, que a menudo preceden a la parada cardiorrespiratoria. Por este motivo, se procedió a la creación de un segundo dataset que incorporara límites inferiores de seguridad. La nueva lógica establecida fue la siguiente:

- FC: 2 ptos si es inferior a 90 o superior a 160, 1 pto si es mayor o igual a 140, 0 ptos para el resto de los casos.
- FR: 2 ptos si es inferior a 20 o superior a 60, 1 pto si es mayor o igual a 40, 0 ptos para el resto de los casos.
- SpO2: 0 ptos si es mayor o igual a 95, 1 si es mayor o igual a 90, 2 para el resto.
- Apariencia: 2-3 ptos si el SpO2 es menor a 90 o la FR es menor o igual a 20, 0-1 ptos para el resto.

Aunque esta modificación aumentó la complejidad del problema y redujo la precisión nominal del modelo al 80.00%, se priorizó la fidelidad clínica y la seguridad del paciente sobre las métricas puramente matemáticas, garantizando un sistema robusto capaz de alertar ante cualquier desviación extrema de la normalidad.

Algoritmos empleados

Árbol de decisión

Un árbol de decisión es un algoritmo de aprendizaje supervisado que modela decisiones y sus posibles consecuencias mediante una estructura jerárquica en forma de árbol. Cada nodo interno representa una prueba sobre un atributo del conjunto de datos, cada rama corresponde al resultado de dicha prueba, y cada nodo hoja contiene una etiqueta de clase (en clasificación) o un valor numérico (en regresión).

El proceso de construcción, denominado inducción del árbol, parte de un nodo raíz que agrupa la totalidad de las instancias de entrenamiento. En cada paso, el algoritmo selecciona el atributo más informativo para realizar la partición del conjunto de datos. Esta selección se basa en criterios cuantitativos como la ganancia de información (basada en la entropía de Shannon), el índice de Gini o la reducción de varianza, dependiendo del tipo de tarea. El objetivo es maximizar la homogeneidad de las particiones resultantes, es decir, que cada subconjunto contenga instancias lo más similares posible entre sí.

El proceso de partición se repite de forma recursiva en cada subárbol hasta alcanzar una condición de parada: que todos los ejemplos de un nodo pertenezcan a la misma clase, que se supere una profundidad máxima predefinida, o que el número de instancias caiga por debajo de un umbral mínimo. Este mecanismo convierte al árbol de decisión en un algoritmo de tipo divide y vencerás.

Un riesgo inherente a este modelo es el sobreajuste (*overfitting*), que ocurre cuando el árbol memoriza el ruido del conjunto de entrenamiento en lugar de generalizar patrones. Para mitigarlo se aplican técnicas de poda (*pruning*), que pueden ser previas a la construcción (*pre-pruning*) o posteriores (*post-pruning*), eliminando ramas que aportan escasa capacidad predictiva. Entre sus ventajas destacan la interpretabilidad del modelo, su capacidad para manejar variables tanto numéricas como categóricas, y la ausencia de necesidad de normalización de los datos. Además, constituye la base de métodos ensemble de alto rendimiento como Random Forest y Gradient Boosting.

La elección de este algoritmo para el entorno médico es estratégica debido a su alta interpretabilidad, ya que emula el proceso de razonamiento diagnóstico de un facultativo, permitiendo visualizar claramente los umbrales que disparan cada nivel de alerta. Para su implementación, se utilizó una profundidad máxima de cinco niveles (max_depth=5). Esta restricción es crucial para mantener un equilibrio entre la capacidad de aprendizaje y la generalización; un árbol demasiado profundo podría memorizar casos particulares del dataset sintético, perdiendo utilidad ante nuevos pacientes, mientras que uno demasiado simple no captaría las ventanas terapéuticas necesarias. El proceso de validación se realizó mediante una partición de datos 80/20, reservando el 80% para el entrenamiento de la estructura lógica y un 20% independiente para evaluar el rendimiento final sobre datos no vistos, asegurando así la integridad técnica del modelo.

k-NN

El algoritmo k-Nearest Neighbors (k-NN) es un método de aprendizaje supervisado no paramétrico y basado en instancias (*instance-based learning*), lo que significa que no construye un modelo explícito durante la fase de entrenamiento, sino que almacena directamente el conjunto de datos. Por esta razón se denomina también algoritmo de aprendizaje perezoso (*lazy learning*): todo el coste computacional se traslada a la fase de inferencia.

Para clasificar una nueva instancia, el algoritmo calcula la distancia entre dicha instancia y todos los puntos del conjunto de entrenamiento. Las métricas de distancia más empleadas son la distancia Euclídea, la distancia de Manhattan y la distancia de Minkowski (que generaliza a las anteriores). Una vez calculadas las distancias, se identifican los k vecinos más cercanos, es decir, las k instancias del conjunto de entrenamiento con menor distancia a la instancia de consulta. La predicción final se obtiene por votación mayoritaria entre esos k vecinos en tareas de clasificación, o mediante el promedio de sus valores en tareas de regresión.

El hiperparámetro k tiene un impacto directo en el equilibrio entre sesgo y varianza (*bias-variance tradeoff*). Un valor de k pequeño produce fronteras de decisión muy irregulares, con

alta varianza y riesgo de sobreajuste. Un valor de k grande suaviza dichas fronteras, aumentando el sesgo y pudiendo provocar subajuste (*underfitting*). La selección óptima de k se realiza habitualmente mediante validación cruzada (*cross-validation*).

Un desafío crítico del algoritmo es la maldición de la dimensionalidad (*curse of dimensionality*): a medida que el número de características crece, las distancias entre puntos tienden a homogeneizarse, reduciendo el poder discriminativo de la métrica. Para mitigar este problema se aplican técnicas de reducción de dimensionalidad como PCA o selección de características. Adicionalmente, dado que k-NN es sensible a la escala de los atributos, es imprescindible aplicar normalización o estandarización de los datos antes de su uso. Entre sus ventajas destacan la simplicidad de implementación, la ausencia de suposiciones sobre la distribución de los datos y su adaptabilidad natural a problemas multiclase.

Como alternativa para contrastar el rendimiento del sistema, se planteó el uso de este algoritmo. Este método de aprendizaje no genera una estructura de reglas predefinida, sino que clasifica a un nuevo paciente comparando sus signos vitales con los registros más similares presentes en la base de datos. Se propuso como solución debido a su capacidad para manejar fronteras de decisión no lineales, lo cual es ideal para un score médico donde variables como la frecuencia cardíaca y la saturación pueden interactuar de forma compleja. En este modelo, el parámetro "k" se configuró en un valor de 5, buscando promediar la información de los cinco pacientes más cercanos en el espacio de datos. Esta elección busca mitigar el efecto de posibles valores atípicos (outliers) en el dataset sintético, proporcionando una clasificación basada en la vecindad estadística que ofrece una perspectiva distinta a la rigidez lógica de los árboles de decisión.

Naive Bayes

El algoritmo Naive Bayes es un clasificador probabilístico fundamentado en el teorema de Bayes, que describe la probabilidad condicional de un evento dado el conocimiento previo de condiciones relacionadas. Su denominación incluye el término *naive* (ingenuo) porque asume independencia condicional entre todos los atributos del conjunto de datos dado el valor de la clase, una suposición que raramente se cumple en la práctica pero que, paradójicamente, produce resultados competitivos en numerosos problemas reales.

El fundamento matemático del clasificador parte del teorema de Bayes:

$$P(C \mid X) = P(X \mid C) \cdot P(C) / P(X)$$

donde $P(C \mid X)$ es la probabilidad posterior de la clase C dada la instancia X, $P(X \mid C)$ es la verosimilitud (*likelihood*) de observar X bajo la clase C, $P(C)$ es la probabilidad a priori de la clase, y $P(X)$ es la evidencia, que actúa como constante normalizadora. Bajo la suposición de independencia, la verosimilitud conjunta se factoriza como el producto de las verosimilitudes individuales de cada atributo: $P(X \mid C) = \prod P(x_i \mid C)$, lo que reduce drásticamente el coste computacional del cálculo.

Existen distintas variantes del modelo según la distribución asumida para modelar $P(x_i \mid C)$. El Naive Bayes Gaussiano asume que los atributos continuos siguen una distribución normal, estimando la media y varianza de cada atributo por clase. El Naive Bayes Multinomial modela frecuencias de ocurrencia y es ampliamente utilizado en clasificación de texto y análisis de documentos. El Naive Bayes de Bernoulli opera con atributos binarios, indicando presencia o ausencia de una característica, siendo también muy común en tareas de procesamiento de lenguaje natural.

Un problema práctico relevante es el de las probabilidades nulas: si un atributo no aparece en el conjunto de entrenamiento asociado a una clase, su probabilidad es cero y anula todo el producto. Para evitarlo se aplica la suavización de Laplace (*Laplace smoothing*) o la suavización de Lidstone, que añaden un pseudoconteo a cada categoría garantizando que ninguna probabilidad sea exactamente cero. A pesar de su supuesto de independencia, Naive Bayes destaca por su eficiencia computacional, su robustez ante conjuntos de datos pequeños, su facilidad de actualización incremental y su excelente rendimiento en tareas como la detección de spam, el diagnóstico médico y la categorización de documentos.

Este clasificador se implementó como tercer método de ayuda a la decisión. Asume independencia entre las variables de entrada, calculando la probabilidad de que un paciente pertenezca a un nivel de riesgo "Bajo", "Medio" o "Alto" dadas sus constantes vitales actuales. A pesar de que en la fisiología humana existe una correlación intrínseca entre parámetros como la frecuencia respiratoria y la saturación de oxígeno, Naive Bayes se planteó como una solución valiosa debido a su eficiencia computacional y su robustez ante el ruido. Su inclusión en la metodología permite evaluar el problema desde una vertiente probabilística, proporcionando una medida de confianza en la predicción que complementa la visión determinista del Árbol de Decisión y la visión espacial del k-NN, conformando así un marco comparativo exhaustivo para la validación del sistema SAPI.

Resultados

Una vez entrenado un modelo de clasificación, su rendimiento no puede evaluarse únicamente mediante la exactitud global (*accuracy*), ya que esta métrica resulta engañosa en conjuntos de datos con clases desequilibradas. Para obtener una evaluación rigurosa se recurre a un conjunto de métricas derivadas de la matriz de confusión, que cruza las predicciones del modelo con las etiquetas reales. Los cuatro valores fundamentales de dicha matriz son: Verdaderos Positivos (TP), Verdaderos Negativos (TN), Falsos Positivos (FP) y Falsos Negativos (FN).

La precisión mide la proporción de predicciones positivas que son efectivamente correctas. Un valor alto de precisión indica que el modelo genera pocos falsos positivos, es decir, que cuando predice una clase, lo hace con alta fiabilidad. Esta métrica es especialmente crítica en contextos donde un falso positivo tiene un coste elevado.

El recall mide la proporción de instancias positivas reales que el modelo fue capaz de identificar correctamente. Un valor alto de recall implica pocos falsos negativos. Esta métrica cobra

especial importancia cuando el coste de no detectar un caso positivo es alto, como es el caso de los diagnósticos médicos. Existe una tensión natural entre precisión y recall: aumentar uno tiende a reducir el otro, fenómeno conocido como el trade-off precision-recall.

El F1-score es la media armónica entre precisión y recall, y sintetiza ambas métricas en un único valor. Se utiliza la media armónica en lugar de la media aritmética porque penaliza de forma más severa los desequilibrios entre ambas: un modelo con precisión alta pero recall muy bajo obtendrá un F1-score bajo, reflejando que el rendimiento global no es satisfactorio. El valor oscila entre 0 y 1, siendo 1 el rendimiento perfecto. En escenarios con clases desequilibradas, el F1-score por clase ofrece una visión mucho más honesta del comportamiento real del modelo que la exactitud global. Existen generalizaciones de esta métrica, como el Fβ-score, que permite ponderar la importancia relativa de precisión y recall mediante el parámetro β.

El support no es una métrica de rendimiento en sentido estricto, sino un indicador estadístico que refleja el número de instancias reales de cada clase presentes en el conjunto de evaluación. Su interpretación es fundamental para contextualizar las métricas anteriores: una precisión o recall elevados sobre una clase con support muy bajo pueden no ser estadísticamente significativos, mientras que un rendimiento modesto sobre una clase con support alto tiene un impacto real considerable en el comportamiento global del modelo. El support permite además identificar el desbalance de clases en el conjunto de datos, condición que exige estrategias específicas como sobremuestreo (SMOTE), submuestreo o ajuste de pesos de clase.

Además, la herramienta classification_report de scikit-learn reporta otros tipos de promedio como: Macro avg, un promedio simple de cada métrica por clase sin considerar el support, es decir, trata todas las clases por igual independientemente de su frecuencia; Weighted avg, un promedio ponderado por el support de cada clase, que resulta más representativo cuando existe desbalance entre clases.

Interpretación de las métricas

El Árbol de Decisión es el modelo que obtiene el rendimiento más sólido y equilibrado del conjunto evaluado, alcanzando una precisión global del 80%. Analizando su comportamiento por clases, destaca especialmente su capacidad para identificar correctamente los casos de riesgo alto, con una precisión de 0,91, lo que significa que cuando el modelo predice riesgo alto, acierta en el 91% de los casos. Sin embargo, su recall para esta misma clase es de 0,77, indicando que un 23% de los pacientes realmente críticos no son detectados como tales, lo cual representa el punto de mejora más relevante desde el punto de vista clínico. Para la clase medio, el modelo muestra el recall más elevado de las tres clases (0,88), lo que es clínicamente favorable dado que es la clase con mayor soporte (48 instancias) y representa la zona de transición hacia la gravedad. La clase bajo es la más débil del modelo, con un F1-score de 0,75, lo cual es aceptable considerando que los errores en esta categoría tienen menor impacto asistencial. El F1-score global ponderado de 0,80 confirma que el árbol generaliza de forma coherente y consistente a lo largo de las tres categorías de riesgo.

```
Precisión del modelo: 80.00%

Informe de Clasificación:
              precision    recall  f1-score   support

        Alto       0.91      0.77      0.83        26
        Bajo       0.82      0.69      0.75        26
       Medio       0.75      0.88      0.81        48

    accuracy                           0.80       100
   macro avg       0.83      0.78      0.80       100
weighted avg       0.81      0.80      0.80       100
```

Figura 1. Métricas del Árbol de decisión.

El diagrama del árbol de decisión revela con precisión la lógica de partición aprendida por el modelo a partir de los datos sintéticos del sistema SAPI. El nodo raíz establece como criterio principal la variable Apariencia ≤ 1,5, lo cual es clínicamente coherente: la apariencia general del paciente pediátrico es un indicador precoz y global del estado de compromiso fisiológico, y su posición en la cima del árbol refleja que es el atributo con mayor ganancia de información sobre el conjunto de entrenamiento (400 muestras, índice de Gini de 0,653). La rama izquierda, correspondiente a apariencias bajas (≤ 1,5), deriva inmediatamente hacia una segunda partición por FR ≤ 42,5, discriminando entre pacientes con respiración dentro de rangos aceptables y aquellos con taquipnea significativa. En esta rama, el modelo tiende a clasificar hacia las clases Bajo y Medio, con nodos hoja de alta pureza (Gini próximo a 0) en los subárboles más profundos. La rama derecha, correspondiente a apariencias elevadas (> 1,5), parte de inmediato por FC ≤ 87,5, separando la bradicardia —signo de alarma crítica en pediatría— del resto de frecuencias cardiacas, y orienta la clasificación predominantemente hacia Alto. A lo largo del árbol, la variable SpO2 aparece como criterio discriminante en niveles intermedios y profundos, reforzando su papel como confirmador de gravedad una vez que la apariencia y las frecuencias ya han estratificado el riesgo inicial. La profundidad máxima de 5 niveles impuesta en el código limita el sobreajuste sin sacrificar capacidad predictiva, y los nodos hoja con Gini igual a 0,0 evidencian particiones perfectamente puras, especialmente frecuentes en la clase Alto, lo que respalda la alta precisión (0,91) observada en las métricas para dicha clase.

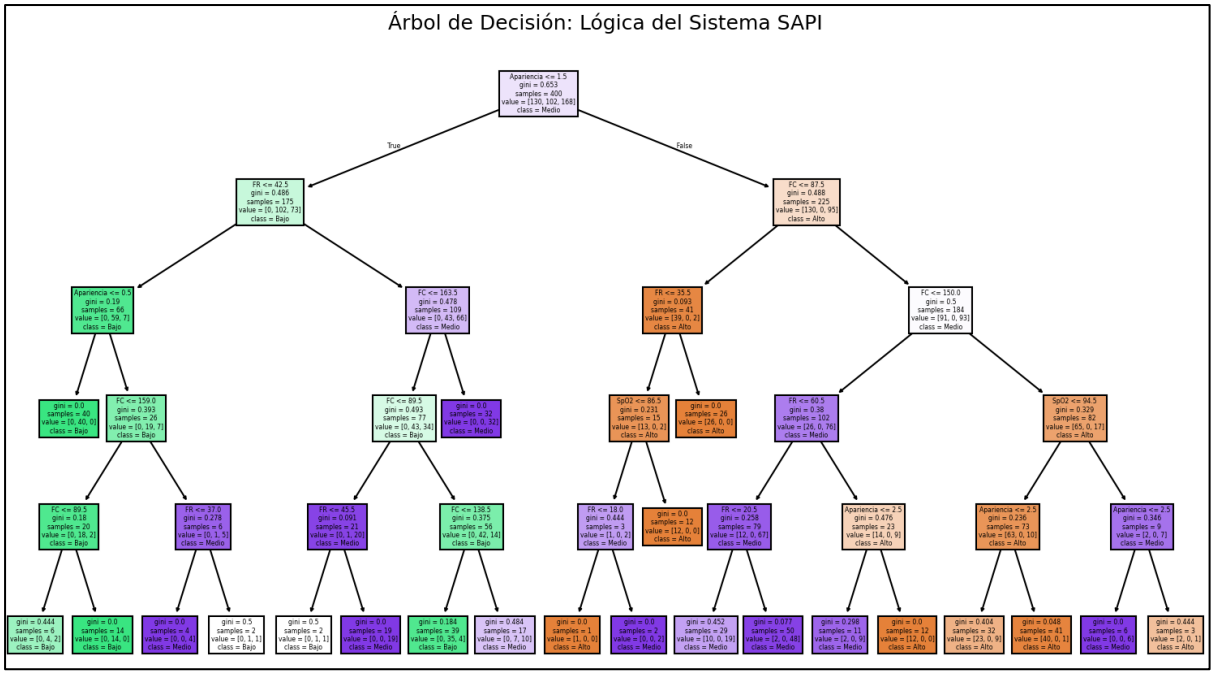


Figura 2. Diagrama del Árbol de decisión.

El modelo k-NN obtiene una precisión global del 75%, cinco puntos por debajo del árbol de decisión, y muestra un perfil de métricas más irregular entre clases. Su comportamiento más preocupante se observa en la clase alto, donde el recall desciende a 0,62, lo que implica que casi cuatro de cada diez pacientes en situación crítica no son identificados correctamente por el modelo. Este resultado es especialmente relevante en el contexto del sistema SAPI, donde la no detección de un riesgo alto constituye un error de consecuencias clínicas graves. En cambio, el modelo muestra un comportamiento más equilibrado en las clases bajo y medio, con F1-scores de 0,77 y 0,76 respectivamente, y un recall de 0,81 para la clase medio que denota una buena sensibilidad en la zona intermedia del score. El rendimiento inferior del k-NN en esta aplicación puede atribuirse en parte a la naturaleza del espacio de atributos: las variables FC, FR, SpO2 y Apariencia generan fronteras de decisión que no son estrictamente lineales ni perfectamente separables por proximidad euclídea, lo que limita la capacidad discriminativa del algoritmo a pesar de haberse aplicado normalización mediante StandardScaler.

```
Precisión k-NN: 75.00%

Informe de Clasificación:
              precision    recall  f1-score   support

        Alto       0.84      0.62      0.71        26
        Bajo       0.77      0.77      0.77        26
       Medio       0.71      0.81      0.76        48

    accuracy                           0.75       100
   macro avg       0.77      0.73      0.75       100
weighted avg       0.76      0.75      0.75       100
```

Figura 3: Métricas del k-NN

El modelo Naive Bayes Gaussiano es el de menor rendimiento global, con una precisión del 65%, pero presenta el perfil de métricas más asimétrico y, por tanto, el más difícil de interpretar de forma global. Su rasgo más llamativo es el recall perfecto de 1,00 en la clase bajo, lo que indica que identifica sin excepción a todos los pacientes de bajo riesgo, pero a costa de clasificar erróneamente otras clases en su favor. Para la clase alto, obtiene un recall de 0,85, el más elevado de los tres modelos en esta categoría crítica, lo que evidencia una alta sensibilidad hacia los extremos del espectro de riesgo. Sin embargo, su comportamiento sobre la clase medio es notablemente deficiente: con un recall de apenas 0,35 y un F1-score de 0,49, el modelo falla en detectar correctamente más de la mitad de los pacientes en riesgo intermedio, que además constituyen la clase mayoritaria del dataset con 48 instancias de soporte. Este desequilibrio es coherente con la suposición de independencia condicional del algoritmo, que resulta especialmente limitante cuando las variables clínicas como FC, FR y SpO2 presentan correlaciones fisiológicas inherentes que el modelo no es capaz de capturar.

```
Precisión Global Naive Bayes: 65.00%

Informe de Clasificación:
              precision    recall  f1-score   support

        Alto       0.55      0.85      0.67        26
        Bajo       0.67      1.00      0.80        26
       Medio       0.81      0.35      0.49        48

    accuracy                           0.65       100
   macro avg       0.68      0.73      0.65       100
weighted avg       0.70      0.65      0.62       100
```

Figura 4. Métricas de Naive Bayes.

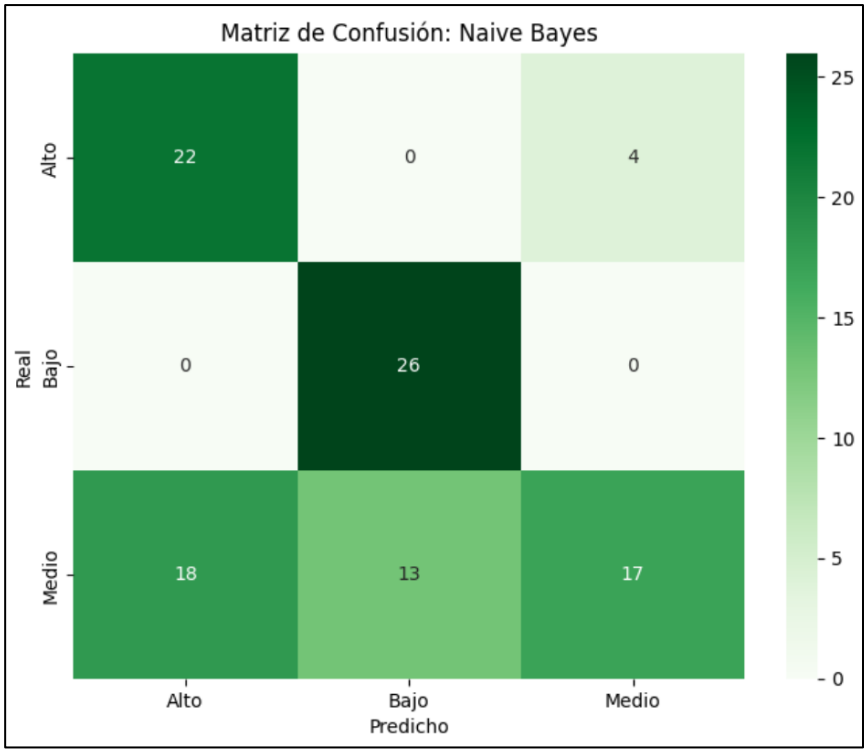


Figura 5. Matriz de confusión de Naive Bayes.

Algoritmo elegido

En términos comparativos, el Árbol de Decisión se posiciona como el modelo más óptimo para el sistema de automatización del score SAPI pediátrico. Su superioridad no reside únicamente en tener la mayor precisión global (80%), sino en ofrecer el perfil de métricas más equilibrado y clínicamente más seguro de los tres: mantiene una alta precisión en la predicción de riesgo alto, una buena sensibilidad en la clase medio y un F1-score ponderado de 0,80 que refleja robustez transversal. Desde una perspectiva clínica, el error más costoso en este sistema es la infradetección del riesgo alto, y el árbol de decisión es el modelo que mejor controla este tipo de error, superando al k-NN en recall para dicha clase (0,77 frente a 0,62). Adicionalmente, la naturaleza interpretable del árbol de decisión representa una ventaja estructural en entornos sanitarios, donde la transparencia del razonamiento del modelo es un requisito ético y funcional: los clínicos pueden inspeccionar las reglas de decisión y validar que los umbrales aplicados son coherentes con la evidencia pediátrica. El k-NN queda como segunda opción viable si se ajusta el valor de k mediante validación cruzada, mientras que Naive Bayes, pese a su alta sensibilidad en los extremos, resulta inadecuado para este problema por su incapacidad de gestionar correctamente la clase de riesgo medio, que es precisamente la más frecuente y la que mayor precisión diagnóstica requiere para orientar la actuación clínica.

Dashboards

Finalmente, se han diseñado dos dashboards con el fin de proporcionar un soporte visual que facilite el análisis de los resultados obtenidos al aplicar el modelo de Árbol de Decisión sobre los datos. Para ambos se ha empleado la herramienta de visualización Power BI.

El primer dashboard presenta una visión global e integrada del rendimiento del modelo sobre las 100 instancias del conjunto de prueba. El gráfico de dispersión representa la correlación fisiológica entre FC (eje X) y SpO2 (eje Y), coloreando cada punto según el riesgo predicho: rojo para Alto, verde para Bajo y amarillo para Medio. El patrón espacial es fisiológicamente interpretable: los puntos rojos se concentran en las zonas de SpO2 más baja (por debajo de 90%) y en los extremos de la FC, tanto en bradicardia (< 80 bpm) como en taquicardia severa (> 160 bpm), zonas que corresponden a los criterios de puntuación máxima del score SAPI. Los puntos verdes se agrupan en la franja superior del gráfico (SpO2 > 93%) con frecuencias cardiacas dentro de rangos intermedios, y los amarillos ocupan la zona de transición entre ambos grupos, reflejando la naturaleza continua del riesgo clínico. La matriz de confusión muestra que, de los 26 casos reales de riesgo Alto, el modelo clasifica correctamente 20 e interpreta 6 como Medio, ninguno como Bajo, lo cual es clínicamente relevante: el modelo nunca infravalora un riesgo alto hasta el nivel de bajo, conteniendo el error más peligroso. En la clase Bajo, clasifica correctamente 18 de 26, desviando 8 hacia Medio, un error conservador y aceptable. Para la clase Medio, que tiene el mayor soporte con 48 instancias, acierta en 42 casos, con solo 2 desviados a Alto y 4 a Bajo, lo que confirma la solidez del modelo en la categoría más prevalente. En conjunto, la precisión global del 80% y la ausencia de confusiones cruzadas entre los extremos (Alto y Bajo) validan que el árbol de decisión constituye una herramienta de soporte clínico fiable para la estratificación automatizada del riesgo SAPI en pacientes pediátricos.

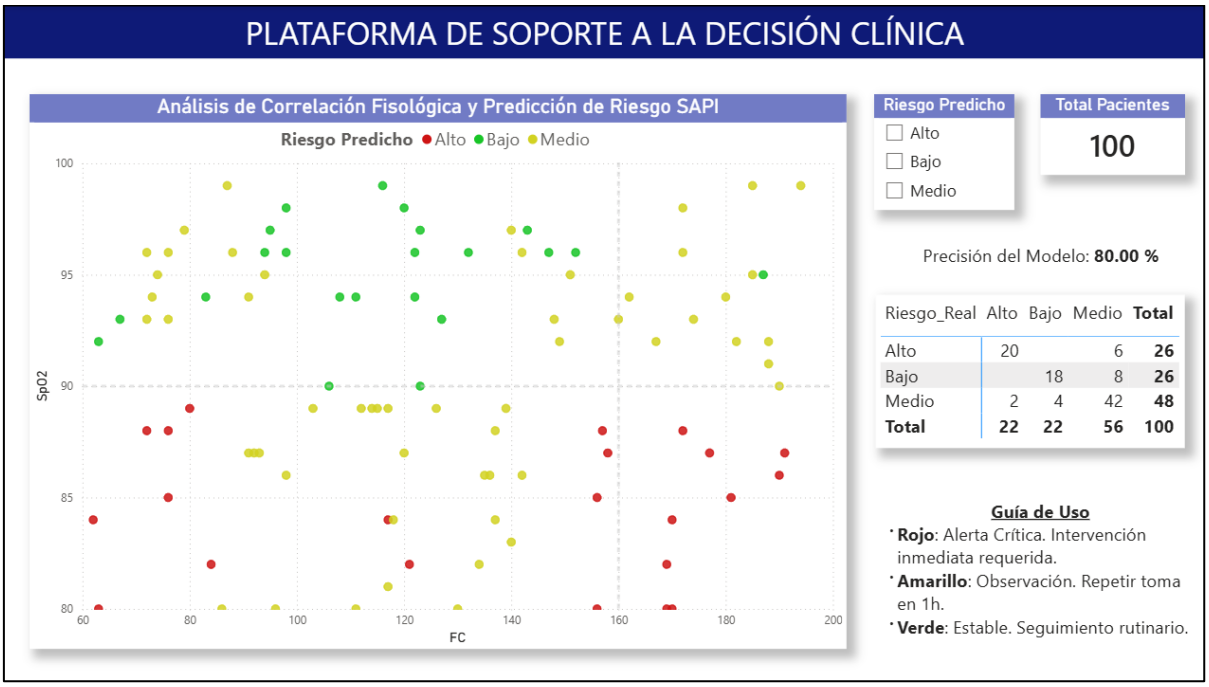


Figura 6. Dashboard 1.

El segundo dashboard simula un monitor de cabecera clínica con el resultado del cálculo del SAPI integrado en la interfaz. La creación de este dashboard responde a la necesidad de transformar el modelo matemático en una herramienta de ayuda a la decisión real. En este entorno, los datos dejan de ser filas en un CSV para convertirse en información procesada en tiempo real. El monitor visualiza las constantes (FC, FR, SpO2) y, de forma automática, destaca el score SAPI resultante y el riesgo asociado. Este sistema permite al personal de enfermería y medicina centrarse en el paciente mientras el algoritmo realiza la vigilancia constante de los umbrales fisiológicos.

La arquitectura de este sistema de monitorización está concebida para la integración y el procesamiento de flujos de datos biomédicos en tiempo real, garantizando una vigilancia continua de la estabilidad del neonato. No obstante, dado que el dataset de entrenamiento se compone de registros transversales de múltiples pacientes, para la validación funcional de este dashboard se ha optado por un escenario representativo basado en los valores centrales (medianas) de la FC, la FR, el SpO_2 y la apariencia clínica. Para mostrar los puntos asignados en cada dominio, se han implementado campos calculados definidos por las mismas expresiones de la lógica del SAPI empleada en el programa en que se generaban los datos sintéticos.

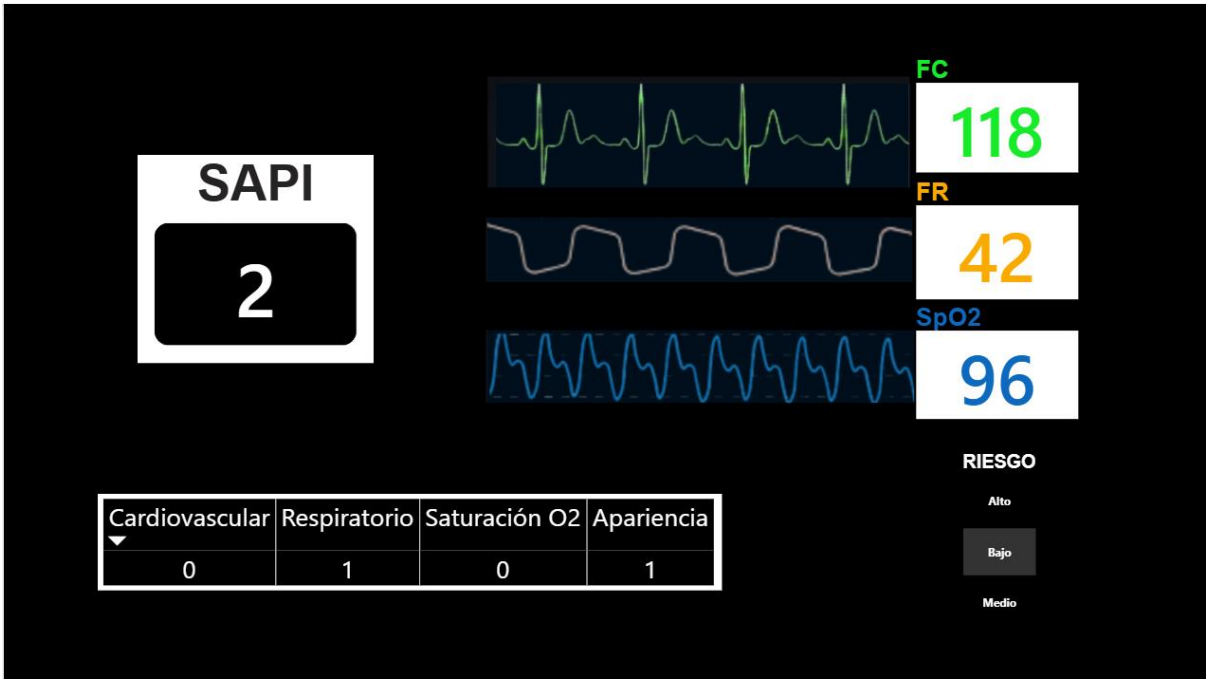


Figura 7. Dashboard 2.

Conclusiones

El presente SADC surge como respuesta a la necesidad de mitigar la subjetividad y la variabilidad inherentes a los procesos de evaluación manual en pediatría. La automatización del score SAPI no solo optimiza la eficiencia operativa del personal facultativo, sino que eleva

la calidad asistencial al proporcionar una herramienta de cribado objetiva y reproducible. A través de este trabajo, se ha demostrado que la implementación de algoritmos de aprendizaje supervisado, específicamente el Árbol de Decisión, permite capturar la complejidad de la fisiología neonatal mediante una lógica de clasificación no lineal.

De cara al futuro, la integración de estos algoritmos en la Historia Clínica Electrónica (HCE) facilitará el desarrollo de modelos predictivos capaces de anticipar la necesidad de ingreso en UCI, transformando datos estáticos en indicadores dinámicos de evolución. Asimismo, su convergencia con sistemas de monitorización continua permitirá el análisis de tendencias temporales y patrones de inestabilidad hemodinámica, posicionando a la inteligencia artificial como un aliado estratégico en la detección precoz del deterioro clínico en pacientes críticos.

Referencias bibliográficas

Mendoza Chate, L. (2020). *Estudio comparativo de Naive Bayes, Árbol de Decisión, Redes Neuronales y K-NN para la clasificación de datos*. ResearchGate. (PDF) Estudio Comparativo de Naive Bayes, Árbol de Decisión, Redes Neuronales y K-NN

Kashyap, P. (2024). *Understanding Precision, Recall, and F1 Score Metrics*. Medium. Understanding Precision, Recall, and F1 Score Metrics | by Piyush Kashyap | Medium

Pérez-Moreno, J., Gónzalez Martínez, F., & Toledo del Castillo, B. (2021). *Protocolo SEPIH 9: Sistemas de Alerta Precoz Infantil (SAPI) en el niño hospitalizado*. Sociedad Española de Pediatría Interna Hospitalaria (SEPIH). protocolo-sepih-9-sistemas-de-alerta-precoz-infantil-en-el-nino-hospitalizado.pdf

Sociedad Argentina de Pediatría. (s. f.). *Utilidad de una escala de alerta temprana como predictor precoz de deterioro clínico en niños internados.* v118n6a08.pdf